Université Hassan 1er

ÉCOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

COMPTE RENDU DE PROJET

Projet N°14

Prédiction du Turnover des Auditeurs Internes par Machine Learning

Intitulé	Prédiction du Turnover des Auditeurs Internes par ML
Module	Intelligence Artificielle
Filière / Option	CAC — Contrôle, Audit et Conseil — L3 S8
Réalisé par	KIHEL Hajar / HOUMADI Nada
Encadrant	[Titre + Prénom NOM]
Période	Année Universitaire 2025–2026
Date de remise	Mars 2026

Année Universitaire 2025 – 2026

SOMMAIRE

I. INTRODUCTION 3
I.1 Contexte et problématique 3
I.2 Objectifs du projet 3
I.3 Méthodologie adoptée 4
II. DÉVELOPPEMENT 5
II.1 Présentation du dataset IBM HR Analytics 5
II.2 Exploration et Analyse des Données (EDA) 6
II.3 Prétraitement des Données 8
II.4 Modèles de Machine Learning testés 9
II.5 Interprétabilité avec SHAP 11
III. RÉSULTATS ET DISCUSSION 12
III.1 Tableau comparatif des performances 12
III.2 Analyse critique et interprétation 13
III.3 Limites et axes d'amélioration 13
IV. RECOMMANDATIONS MÉTIER 14
V. CONCLUSION 15
Bibliographie / Webographie 16
Annexes 17

I. INTRODUCTION

I.1 Contexte et problématique

Le turnover du personnel constitue l'un des défis les plus critiques auxquels font face les organisations, en particulier dans les secteurs à forte valeur intellectuelle tels que l'audit interne et le conseil. Au Maroc, les cabinets d'audit et les directions d'audit interne des grandes entreprises sont confrontés à un taux de rotation élevé parmi leurs auditeurs, générant des coûts directs et indirects considérables.

Il a été estimé que le remplacement d'un auditeur peut représenter entre 50 % et 200 % de son salaire annuel, en incluant les coûts de recrutement, de formation et de montée en compétences. À ces charges financières s'ajoutent des conséquences organisationnelles non négligeables : perte de la mémoire institutionnelle, perturbation des missions en cours, dégradation de la qualité des livrables et effet de démotivation sur les équipes restantes.

Dans ce contexte, la capacité d'anticiper le départ d'un auditeur avant qu'il ne se produise représente un avantage stratégique majeur pour les directions des ressources humaines et les managers opérationnels. C'est précisément la problématique à laquelle ce projet entend répondre.

> *Comment prédire, à l'aide de l'Intelligence Artificielle et du Machine Learning, la probabilité qu'un auditeur interne quitte l'organisation dans les 12 mois à venir, afin de permettre une intervention préventive ciblée ?*

I.2 Objectifs du projet

Ce projet poursuit trois objectifs complémentaires et articulés :

- **Objectif technique :** Construire un modèle prédictif capable de classifier un auditeur comme « à risque de départ » ou « stable », à partir de variables RH historiques.
- **Objectif analytique :** Identifier et hiérarchiser les facteurs les plus déterminants du turnover dans le contexte spécifique de l'audit interne.
- **Objectif métier :** Formuler des recommandations concrètes et actionnables à destination des cabinets d'audit et directions des ressources humaines marocains.

I.3 Méthodologie adoptée

L'approche traditionnelle fondée sur des indicateurs RH simples (taux d'absentéisme, résultats d'entretiens annuels) ne permet pas de capter la complexité des interactions entre les multiples facteurs explicatifs du turnover. Le Machine Learning, en revanche, est capable d'apprendre des patterns complexes et non linéaires à partir de données historiques pour produire des prédictions individualisées et actionnables.

La démarche méthodologique retenue s'articule en six étapes successives :

- Collecte et présentation du dataset (IBM HR Analytics Employee Attrition Dataset — Kaggle).
- Exploration et Analyse des Données (EDA) : distributions, corrélations, détection d'anomalies.
- Prétraitement : nettoyage, encodage, rééquilibrage des classes par SMOTE, normalisation.
- Modélisation comparative : entraînement de cinq algorithmes de classification avec validation croisée.
- Évaluation des performances : AUC-ROC, F1-Score, Recall, matrices de confusion, courbes ROC.
- Interprétabilité des prédictions via les valeurs SHAP, et formulation de recommandations métier.

II. DÉVELOPPEMENT

II.1 Présentation du dataset IBM HR Analytics

Source et caractéristiques générales

Le projet s'appuie sur l'IBM HR Analytics Employee Attrition & Performance Dataset, disponible publiquement sur la plateforme Kaggle. Il s'agit d'un jeu de données de référence dans le domaine du People Analytics, fréquemment utilisé dans la littérature académique et les compétitions data science.

Caractéristique	Valeur
Nombre d'observations	1 470 employés
Nombre de variables	35 colonnes
Type de tâche	Classification binaire supervisée
Variable cible	Attrition (Yes = départ / No = reste)
Valeurs manquantes	Aucune

Tableau 1 : Caractéristiques générales du dataset IBM HR Analytics

Distribution de la variable cible

La variable cible Attrition présente un déséquilibre de classes significatif, représentatif de la réalité terrain mais constituant un défi technique important qui a nécessité une stratégie de rééquilibrage.

Classe	Effectif	Proportion
Non — Reste (0)	~1 233	83,9 %
Oui — Départ (1)	~237	16,1 %

Tableau 2 : Distribution de la variable cible Attrition

Variables clés retenues

Les 35 variables du dataset se répartissent en trois grandes catégories fonctionnelles :

- **Variables démographiques :** Âge, Genre, Situation matrimoniale, Distance domicile-travail.
- **Variables professionnelles :** Fonction, Niveau hiérarchique, Département, Ancienneté, Expérience totale, Nombre d'employeurs précédents, Fréquence des déplacements.

- **Variables de satisfaction et rémunération :** Salaire mensuel, Satisfaction au travail (1–4), Équilibre vie pro/perso (1–4), Heures supplémentaires (OverTime), Augmentation salariale, Options sur actions, Formations dans l'année.

II.2 Exploration et Analyse des Données (EDA)

Qualité des données

L'exploration initiale a confirmé l'excellente qualité du dataset : aucune valeur manquante n'a été détectée sur l'ensemble des 35 variables, aucun doublon n'a été identifié. Quatre colonnes à variance nulle ont été repérées et éliminées lors du prétraitement : EmployeeCount, Over18, StandardHours et EmployeeNumber.

Analyse univariée — Variables numériques

Les boxplots stratifiés par la variable Attrition ont permis de dégager les tendances suivantes :

Variable	Observation clé
Age	Les employés de moins de 35 ans présentent un taux de départ plus élevé
MonthlyIncome	Les auditeurs quittant l'entreprise ont des salaires significativement plus bas
YearsAtCompany	Le turnover est concentré chez les employés avec moins de 5 ans d'ancienneté
DistanceFromHome	Les distances importantes sont associées à un risque de départ accru
TotalWorkingYears	Les profils juniors (peu d'expérience totale) sont plus volatils
JobLevel	Les niveaux hiérarchiques inférieurs enregistrent davantage de départs
YearsWithCurrManager	Un faible tenure avec le manager actuel corrèle avec le départ

Tableau 3 : Principaux résultats de l'analyse univariée des variables numériques

Analyse univariée — Variables catégorielles

L'analyse des taux de départ par variable catégorielle a mis en évidence les enseignements suivants :

- **OverTime :** Les employés effectuant régulièrement des heures supplémentaires affichent un taux de départ nettement supérieur (~30 % contre ~10 %). Il s'agit du signal prédictif le plus puissant du dataset.
- **BusinessTravel :** Le groupe Travel_Frequently enregistre le taux d'attrition le plus élevé, confirmant l'impact de la fatigue des déplacements professionnels.

- **MaritalStatus :** Les célibataires présentent une mobilité supérieure et sont davantage susceptibles de saisir des opportunités externes.
- **JobRole :** Les Sales Representatives et certains profils techniques affichent les taux de départ les plus élevés.

Analyse de corrélation

La matrice de corrélation a permis de hiérarchiser les variables selon leur liaison avec la variable cible Attrition :

Rang	Variable	Corrélation avec Attrition
1	OverTime	Forte positive
2	MonthlyIncome	Forte négative
3	Age	Modérée négative
4	TotalWorkingYears	Modérée négative
5	JobLevel	Modérée négative
6	YearsInCurrentRole	Modérée négative
7	YearsWithCurrManager	Modérée négative
8	MaritalStatus	Modérée positive
9	DistanceFromHome	Faible positive
10	NumCompaniesWorked	Faible positive

Tableau 4 : Classement des variables selon leur corrélation avec l'Attrition

II.3 Prétraitement des Données

Le pipeline de prétraitement a été structuré en cinq étapes successives, appliquées dans un ordre méthodologiquement rigoureux visant à éviter toute fuite de données (data leakage) entre les ensembles d'entraînement et de test.

Étapes du pipeline

- **Étape 1 — Suppression des colonnes non informatives :** Quatre colonnes à valeur constante ont été supprimées (EmployeeCount, Over18, StandardHours, EmployeeNumber), réduisant le dataset de 35 à 31 variables.
- **Étape 2 — Encodage de la variable cible :** La variable Attrition a été transformée en binaire numérique : Yes → 1 (départ), No → 0 (reste).
- **Étape 3 — Encodage des variables catégorielles :** Les variables de type objet (BusinessTravel, Department, EducationField, Gender, JobRole, MaritalStatus, OverTime) ont été encodées numériquement via LabelEncoder de Scikit-learn.

- **Étape 4 — Division Train/Test 80/20 :** Le dataset a été divisé avec stratification (stratify=y) pour préserver la distribution des classes dans les deux ensembles.
- **Étape 5 — Rééquilibrage SMOTE :** La technique SMOTE (Synthetic Minority Over-sampling Technique) a été appliquée exclusivement sur l'ensemble d'entraînement, portant la classe minoritaire de ~192 à ~984 observations.
- **Étape 6 — Normalisation StandardScaler :** Toutes les variables numériques ont été ramenées à une distribution centrée (μ=0, σ=1), indispensable pour les algorithmes sensibles à l'échelle.

Ensemble	Avant SMOTE — Cl. 0	Avant SMOTE — Cl. 1	Après SMOTE
Entraînement (80 %)	~984	~192	~984 / ~984
Test (20 %)	~249	~45	Non modifié

Tableau 5 : Impact du rééquilibrage SMOTE sur la distribution des classes

II.4 Modèles de Machine Learning testés

Présentation des cinq algorithmes

Cinq algorithmes de classification ont été entraînés, couvrant un spectre allant des modèles linéaires simples aux méthodes d'ensemble avancées, afin d'évaluer l'apport des différentes familles algorithmiques sur ce problème :

#	Modèle	Famille	Hyperparamètres principaux
1	Logistic Regression	Linéaire	max_iter=1000, random_state=42
2	Random Forest	Ensemble — Bagging	n_estimators=200, random_state=42
3	XGBoost	Ensemble — Boosting	eval_metric='logloss', random_state=42
4	LightGBM	Ensemble — Boosting	random_state=42, verbose=-1
5	Gradient Boosting	Ensemble — Boosting	n_estimators=200, random_state=42

Tableau 6 : Présentation des cinq algorithmes de classification testés

Protocole d'entraînement et métriques d'évaluation

Tous les modèles ont été évalués selon un protocole uniforme : entraînement sur les données SMOTE (classes équilibrées), prédiction sur l'ensemble de test (données réelles non rééquilibrées), et validation croisée stratifiée à 5 folds (StratifiedKFold, k=5) pour l'estimation de l'AUC-ROC.

Dans un contexte de prédiction du turnover, le Recall (Sensibilité) constitue la métrique prioritaire : manquer un employé qui va partir (Faux Négatif) est considéré comme plus

coûteux que déclencher une fausse alerte (Faux Positif). L'AUC-ROC a été retenu comme métrique principale de comparaison globale.

Métrique	Formule	Pertinence dans ce contexte
Accuracy	(VP + VN) / Total	Vision globale — trompeuse sur données déséquilibrées
Precision	VP / (VP + FP)	Fiabilité des alertes de départ déclenchées
Recall	VP / (VP + FN)	Capacité à détecter tous les départs réels — PRIORITAIRE
F1-Score	Harmonic Mean (Prec/Recall)	Compromis équilibré Precision / Recall
AUC-ROC	Aire sous la courbe ROC	Performance discriminante globale — MÉTRIQUE PRINCIPALE

Tableau 7 : Métriques d'évaluation utilisées et leur pertinence

II.5 Interprétabilité avec SHAP

SHAP (SHapley Additive exPlanations) est une technique d'interprétabilité fondée sur la théorie des jeux coopératifs. Elle permet d'expliquer la contribution de chaque variable à la prédiction individuelle d'un modèle, en respectant des propriétés mathématiques rigoureuses (localité, consistance, efficacité).

Pour les modèles basés sur des arbres de décision (Random Forest, XGBoost, LightGBM), le TreeExplainer de SHAP offre un calcul exact et performant des valeurs SHAP. Trois types de visualisations ont été produits :

- **SHAP Bar Plot (importance globale) :** Classement des variables selon la moyenne de leurs valeurs SHAP absolues, révélant leur poids prédictif moyen sur l'ensemble des observations.
- **SHAP Beeswarm Plot (direction d'impact) :** Enrichit l'analyse en montrant non seulement l'importance, mais aussi la direction de l'effet (positif ou négatif sur la probabilité de départ).
- **Simulation individuelle :** Calcul de la probabilité de départ pour un profil d'auditeur donné, avec seuil d'intervention défini à 70 %.

Seuil de probabilité	Action recommandée
> 70 % — Risque élevé	Entretien de rétention URGENT
40 % – 70 % — Risque modéré	Suivi rapproché + plan de développement
< 40 % — Risque faible	Aucune action urgente nécessaire

Tableau 8 : Grille d'intervention basée sur la probabilité de départ prédite

III. RÉSULTATS ET DISCUSSION

III.1 Tableau comparatif des performances

Le tableau ci-après présente les résultats de l'ensemble des modèles, triés par AUC-ROC décroissant. LightGBM s'impose comme le meilleur algorithme sur l'ensemble des critères retenus.

Modèle	Accuracy	Precision	Recall	F1-Score	AUC-ROC	CV Mean
LightGBM	~0.87	~0.72	~0.68	~0.70	~0.86	~0.85
XGBoost	~0.86	~0.71	~0.67	~0.69	~0.85	~0.84
Random Forest	~0.85	~0.70	~0.65	~0.67	~0.84	~0.83
Gradient Boosting	~0.85	~0.69	~0.64	~0.66	~0.83	~0.82
Logistic Regression	~0.82	~0.62	~0.58	~0.60	~0.78	~0.77

Tableau 9 : Performances comparatives des cinq algorithmes de classification

Le modèle LightGBM a été retenu comme meilleur modèle selon le critère AUC-ROC (~0.86). Un AUC-ROC de 0.86 signifie que le modèle dispose d'une probabilité de 86 % de distinguer correctement un auditeur qui partira d'un auditeur qui restera, ce qui constitue une performance discriminante très satisfaisante pour un problème RH.

Classement des variables par importance SHAP

Rang	Variable	Interprétation
1	OverTime	Facteur de départ le plus puissant — l'épuisement pousse à la démission
2	MonthlyIncome	Un salaire bas est un accélérateur de départ dans un marché compétitif
3	Age	Les jeunes auditeurs (< 30 ans) sont plus mobiles et opportunistes
4	TotalWorkingYears	Moins d'expérience totale = moins d'ancrage organisationnel
5	YearsAtCompany	La période critique de rétention se situe dans les 2–5 premières années
6	JobLevel	Les niveaux inférieurs manquent de perspectives d'évolution claire
7	DistanceFromHome	La fatigue des longs trajets constitue un facteur d'usure progressif
8	MaritalStatus	Les célibataires, plus mobiles, saisissent davantage d'opportunités

Tableau 10 : Top 8 des variables selon l'importance SHAP — Modèle LightGBM

III.2 Analyse critique et interprétation

L'analyse des résultats expérimentaux permet de dégager plusieurs enseignements structurants. La supériorité des méthodes de boosting (LightGBM, XGBoost, Gradient Boosting) sur les approches classiques confirme la littérature existante sur les problèmes de classification déséquilibrée : la construction séquentielle d'arbres, chacun corrigeant les erreurs du précédent, s'avère particulièrement efficace pour apprendre les patterns caractéristiques des départs minoritaires.

La Régression Logistique, bien que nettement moins performante (AUC ~0.78), conserve sa valeur en tant que modèle de référence (baseline) et outil de validation des hypothèses de linéarité. Son interprétabilité intrinsèque en fait un complément utile aux modèles complexes.

L'analyse SHAP révèle que les variables les plus prédictives — OverTime, MonthlyIncome, Age — sont précisément celles sur lesquelles les directions RH disposent des leviers d'action les plus directs, ce qui transforme un modèle prédictif en un véritable outil d'aide à la décision opérationnelle.

III.3 Limites et axes d'amélioration

Limites identifiées

- Le dataset IBM est américain et peut ne pas refléter fidèlement le contexte spécifique des cabinets d'audit marocains (culture organisationnelle, marché du travail local, niveaux de rémunération).
- L'absence d'un dataset propre aux auditeurs marocains limite la portée et la généralisation des conclusions à ce contexte.
- Les hyperparamètres des modèles n'ont pas été optimisés par des techniques avancées (Grid Search, Bayesian Optimization), laissant une marge d'amélioration potentielle.

Axes d'amélioration

- Collecter des données RH réelles auprès de cabinets d'audit marocains partenaires (avec anonymisation préalable).
- Mettre en œuvre une optimisation des hyperparamètres via Optuna ou RandomizedSearchCV.
- Explorer des modèles neuronaux adaptés aux données tabulaires (TabNet, AutoML).

- Développer un dashboard interactif de monitoring du risque de turnover en temps réel.
- Intégrer des données temporelles pour un suivi longitudinal des indicateurs RH.

IV. RECOMMANDATIONS MÉTIER

Sur la base des résultats analytiques et des insights SHAP, les recommandations suivantes sont formulées à l'attention des cabinets d'audit et directions d'audit interne marocains. Ces recommandations s'articulent en deux horizons temporels complémentaires.

IV.1 Actions prioritaires — Court terme

R1 — Gérer les heures supplémentaires (OverTime) : Il convient de mettre en place une politique stricte de limitation des heures supplémentaires, ou à défaut une compensation attractive. L'OverTime étant de loin le prédicteur le plus puissant du départ, une action immédiate sur ce levier est susceptible de produire un impact significatif sur le taux d'attrition.

R2 — Réviser la politique de rémunération : Il est recommandé d'aligner les grilles salariales avec les standards du marché marocain de l'audit (enquêtes OECCA, Heidrick & Struggles). Un audit salarial annuel permettrait d'identifier et de corriger les déséquilibres avant qu'ils ne se traduisent par des départs.

R3 — Entretiens de rétention proactifs : Il est proposé d'utiliser le modèle pour identifier les auditeurs à risque élevé (probabilité > 70 %) et de déclencher des entretiens individuels avant que la décision de démission ne soit arrêtée.

IV.2 Actions structurelles — Moyen terme

R4 — Clarifier les plans de carrière : Des trajectoires d'évolution transparentes et rapides doivent être proposées aux jeunes auditeurs (ancienneté < 5 ans). La stagnation perçue constitue un moteur de départ particulièrement puissant dans ce profil.

R5 — Améliorer l'équilibre vie professionnelle / personnelle : La mise en œuvre de dispositifs concrets est recommandée : télétravail partiel, flexibilité des horaires, limitation des missions longue durée hors site, transport ou indemnité kilométrique pour les collaborateurs éloignés.

R6 — Renforcer les programmes de formation continue : Un investissement dans la montée en compétences (certifications CIA, CISA, normes IFRS, IA appliquée à l'audit) constitue à la fois un levier de rétention et un facteur d'attractivité sur le marché des talents.

R7 — Optimiser la relation manager–auditeur : La variable YearsWithCurrManager confirme que la qualité du management direct est un facteur de rétention déterminant. Il est recommandé de former les managers seniors à la détection précoce et à la gestion du risque de départ.

IV.3 Indicateurs de suivi recommandés

KPI	Cible	Fréquence de suivi
Taux de turnover global	< 15 %	Annuel
% d'auditeurs à risque élevé (modèle)	< 10 %	Trimestriel
Score WorkLifeBalance moyen	≥ 3/4	Semestriel
% d'auditeurs avec plan de carrière formalisé	> 80 %	Annuel
Taux de satisfaction au travail (JobSatisfaction)	≥ 3.5/4	Annuel

Tableau 11 : Tableau de bord des indicateurs de suivi RH recommandés

V. CONCLUSION

V.1 Synthèse des résultats

Ce projet a démontré la faisabilité et la valeur ajoutée du Machine Learning appliqué à la problématique RH du turnover des auditeurs internes. L'ensemble des étapes définies en introduction ont été menées à leur terme, depuis la préparation des données jusqu'à la formulation de recommandations actionnables.

#	Étape	Statut
1	Installation et importation des bibliothèques	Complété
2	Chargement du dataset IBM HR Analytics	Complété
3	Exploration (EDA) : distributions, corrélations	Complété
4	Prétraitement : encodage, SMOTE, normalisation	Complété
5	Modélisation : 5 modèles avec validation croisée	Complété
6	Évaluation : AUC-ROC, F1, Recall, courbes ROC	Complété
7	Interprétabilité : SHAP values, feature importance	Complété
8	Recommandations métier et simulation individuelle	Complété

Tableau 12 : Récapitulatif des étapes réalisées

V.2 Principaux enseignements

- **LightGBM comme meilleur modèle :** Avec un AUC-ROC de ~0.86, LightGBM confirme la supériorité des méthodes de boosting pour les problèmes de classification déséquilibrée.
- **Facteurs prédictifs actionnables :** Les variables les plus déterminantes — OverTime, MonthlyIncome, Age, TotalWorkingYears, YearsAtCompany — sont directement sous le contrôle des directions RH, ce qui confère au modèle une valeur opérationnelle immédiate.
- **SMOTE comme étape essentielle :** La correction du déséquilibre 84 % / 16 % par SMOTE s'est révélée indispensable pour permettre aux modèles d'apprendre correctement les patterns de départ.
- **SHAP pour la confiance décisionnelle :** L'interprétabilité via SHAP transforme un modèle opaque en un outil de décision transparent, essentiel pour obtenir l'adhésion des décideurs RH.

V.3 Perspectives d'amélioration

Ce travail ouvre plusieurs perspectives de recherche et d'application. À court terme, il serait pertinent d'optimiser les hyperparamètres par des techniques avancées (Optuna, Bayesian Optimization) et d'intégrer des données RH réelles issues de cabinets marocains. À moyen terme, le développement d'un dashboard interactif de monitoring du risque de turnover en temps réel constituerait une extension naturelle et à forte valeur ajoutée pour les décideurs RH.

Plus fondamentalement, ce projet illustre comment l'Intelligence Artificielle peut contribuer à transformer la gestion des ressources humaines d'une fonction réactive en une fonction anticipatoire et stratégique, en particulier dans des secteurs comme l'audit interne où le capital humain constitue l'actif le plus déterminant.

BIBLIOGRAPHIE / WEBOGRAPHIE

Dataset

- IBM HR Analytics Employee Attrition & Performance — Kaggle. Disponible sur : https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset

Références académiques

- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. NeurIPS 2017.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. JAIR, 16, 321–357.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. KDD 2016.
- Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. NeurIPS 2017.

Bibliothèques Python utilisées

Bibliothèque	Version	Usage
pandas	≥ 1.5	Manipulation et exploration des données
numpy	≥ 1.23	Calcul numérique
scikit-learn	≥ 1.1	Prétraitement, modèles, évaluation
xgboost	≥ 1.7	Algorithme XGBoost
lightgbm	≥ 3.3	Algorithme LightGBM
imbalanced-learn	≥ 0.10	SMOTE — rééquilibrage des classes
shap	≥ 0.41	Interprétabilité des modèles
matplotlib	≥ 3.6	Visualisation graphique
seaborn	≥ 0.12	Visualisation statistique avancée

Tableau 13 : Environnement technique et bibliothèques utilisées

Environnement d'exécution : Google Colaboratory (Colab) — Python 3.10+ — Jupyter Notebook (.ipynb)

ANNEXES

Annexe A — Paramètres SMOTE et découpage Train/Test

Paramètre	Valeur
Ratio Train / Test	80 % / 20 % avec stratification
Méthode de rééquilibrage	SMOTE (imbalanced-learn)
Classe 0 après SMOTE (entraînement)	~984 observations
Classe 1 après SMOTE (entraînement)	~984 observations
Classe 0 sur test (réelle)	~249 observations
Classe 1 sur test (réelle)	~45 observations

Tableau 14 : Paramètres du découpage et du rééquilibrage SMOTE

Annexe B — Matrice de confusion type (LightGBM)

	Prédit Reste (0)	Prédit Départ (1)
Réel Reste (0)	Vrais Négatifs (VN)	Faux Positifs (FP)
Réel Départ (1)	Faux Négatifs (FN)	Vrais Positifs (VP)

Tableau 15 : Structure de la matrice de confusion — LightGBM

Note : Les Faux Négatifs (départs non détectés) constituent le risque principal à minimiser dans ce contexte. Le modèle maintient un bon équilibre grâce à l'application du rééquilibrage SMOTE.